

```
In [1]: import pandas as pd
import os
import matplotlib.pyplot as plt
import numpy as np
from datetime import datetime
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Librerías para modelos de machine learning
from sklearn.linear_model import LinearRegression, Ridge, Lasso, ElasticNet
from sklearn.ensemble import RandomForestRegressor, GradientBoostingRegressor
from sklearn.model_selection import train_test_split, cross_val_score, GridSearchCV, TimeSeriesSplit
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score, mean_absolute_percentage_error
from sklearn.preprocessing import StandardScaler, MinMaxScaler, LabelEncoder
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans

# Librerías para encoding categóricas
from category_encoders import TargetEncoder, BinaryEncoder, OrdinalEncoder

# Librerías para series de tiempo
try:
    from prophet import Prophet
except ImportError:
    print("Prophet no instalado. Instalar con: pip install prophet")

try:
    from statsmodels.tsa.arima.model import ARIMA
    from statsmodels.tsa.seasonal import seasonal_decompose
    from statsmodels.tsa.stattools import adfuller
except ImportError:
    print("Statsmodels no instalado. Instalar con: pip install statsmodels")

# XGBoost
try:
    import xgboost as xgb
except ImportError:
    print("XGBoost no instalado. Instalar con: pip install xgboost")

# LightGBM (alternativa a XGBoost)
try:
    import lightgbm as lgb
except ImportError:
    print("LightGBM no instalado. Instalar con: pip install lightgbm")

# Para visualizaciones avanzadas
import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

# Para métricas personalizadas
from scipy import stats
from sklearn.base import BaseEstimator, RegressorMixin

print("Librerías cargadas exitosamente")
print("Listo para comenzar el modelado predictivo")
```

Librerías cargadas exitosamente
Listo para comenzar el modelado predictivo

```
In [2]: import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

# Configurar estilo de gráficos
plt.style.use('default')
sns.set_palette("husl")
```

```
In [3]: project_root = os.path.dirname(os.getcwd())
clean_path = os.path.join(project_root, "data_cleaned")
df = pd.read_parquet(os.path.join(clean_path, "master.parquet"))

print("Dataset cargado correctamente")
print(f"Shape: {df.shape}")
print(f"Período: {df['Fecha'].min()} a {df['Fecha'].max()}")
```

Dataset cargado correctamente
Shape: (3000, 25)
Período: 2024-01-31 00:00:00 a 2024-12-30 00:00:00

```

In [4]: print("=== IMPLEMENTACIÓN ===")

# Paso 1: Crear features limpias SIN encoding todavía
def create_pure_features_no_encoding(df):
    """Features que NO contienen información del target - SIN encoding"""
    df_features = df.copy()

    # Features temporales básicas
    df_features['year'] = df_features['Fecha'].dt.year
    df_features['month'] = df_features['Fecha'].dt.month
    df_features['week'] = df_features['Fecha'].dt.isocalendar().week
    df_features['quarter'] = df_features['Fecha'].dt.quarter
    df_features['day_of_week'] = df_features['Fecha'].dt.dayofweek
    df_features['is_weekend'] = df_features['day_of_week'].isin([5, 6]).astype(int)

    # Features cíclicas
    df_features['month_sin'] = np.sin(2 * np.pi * df_features['month'] / 12)
    df_features['month_cos'] = np.cos(2 * np.pi * df_features['month'] / 12)

    # MANTENER Categoría y Región sin encoding todavía
    # SOLO información de productos (precio, stock)
    df_features['log_precio'] = np.log(df_features['Precio_Unitario'])
    df_features['log_stock'] = np.log(df_features['Stock'])

    return df_features

# Crear features sin encoding
print("Creando features sin leakage...")
df_with_clean_features = create_pure_features_no_encoding(df)

# Paso 2: Agregar por períodos MANTENIENDO las columnas originales
def aggregate_by_period_corrected(df_features, period_cols, target_col):
    """Agregar SOLO el target, manteniendo features promedio"""

    # Seleccionar features que NO son el target
    exclude_cols = ['Cantidad', 'ingreso', 'ID_Venta', 'ID_Cliente', 'ID_Producto',
                    'Método_Pago', 'Estado', 'Nombre', 'Apellido', 'Email',
                    'Fecha_Registro', 'Nombre_producto', 'Descripción_x',
                    'ID_Categoría', 'ID_Metodo', 'Método', 'Descripción_y']

    feature_cols = [col for col in df_features.columns if col not in exclude_cols]

    # Agregar target
    agg_dict = {target_col: 'sum'}

    # Agregar features (promedio para mantener señal)
    for col in feature_cols:
        if col not in period_cols and col != 'Fecha': # No agregar las columnas de groupby
            if df_features[col].dtype in ['int64', 'float64']:
                agg_dict[col] = 'mean'
            else:
                agg_dict[col] = 'first' # Para categóricas

    agg_dict['Fecha'] = 'first' # Para ordenamiento temporal

    result = df_features.groupby(period_cols).agg(agg_dict).reset_index()
    return result

# Crear dataset semanal con features limpias
df_weekly_clean = aggregate_by_period_corrected(
    df_with_clean_features,
    ['year', 'week', 'Categoría', 'Región'],
    'Cantidad'
)

# Renombrar target
df_weekly_clean.rename(columns={'Cantidad': 'demanda_semanal'}, inplace=True)

print(f"Dataset semanal limpio: {df_weekly_clean.shape}")
print(f"Columnas disponibles: {df_weekly_clean.columns.tolist()}")

# Verificar que tenemos las columnas necesarias
print(f"\n¿Existe 'Categoría'? {'Categoría' in df_weekly_clean.columns}")
print(f"¿Existe 'Región'? {'Región' in df_weekly_clean.columns}")

```

```

=== IMPLEMENTACIÓN ===
Creando features sin leakage...
Dataset semanal limpio: (1457, 19)
Columnas disponibles: ['year', 'week', 'Categoría', 'Región', 'demanda_semanal', 'Precio_Unitario', 'Stock', 'anio', 'mes', 'semana', 'month', 'quarter', 'day_of_week', 'is_weekend', 'month_sin', 'month_cos', 'log_precio', 'log_stock', 'Fecha']

¿Existe 'Categoría'? True
¿Existe 'Región'? True

```

In [15]: `df_weekly_clean.head()`

Out[15]:

	year	week	Categoría	Región	demanda_semanal	Precio_Unitario	Stock	anio	mes	semana	month	quarter	day_of_week
0	2024	1	Carnicería	Centro	5	14.25	2429.0	2024	12	1	12	4	
1	2024	1	Carnicería	NEA	3	11.23	1726.0	2024	12	1	12	4	
2	2024	1	Congelados	Buenos Aires	5	15.45	1640.0	2024	12	1	12	4	
3	2024	1	Frutas y Verduras	Buenos Aires	3	6.54	3383.0	2024	12	1	12	4	
4	2024	1	Frutas y Verduras	Patagonia	2	4.21	3545.0	2024	12	1	12	4	

In [5]:

```

# Paso 3: AHORA aplicar encoding DESPUÉS de la agregación
def apply_encoding_after_aggregation(df):
    """Aplicar encoding después de agregar"""
    df_encoded = df.copy()

    # One-hot encoding
    df_encoded = pd.get_dummies(df_encoded, columns=['Categoría', 'Región'], prefix=['Cat', 'Reg'])

    return df_encoded

# Aplicar encoding
df_weekly_encoded = apply_encoding_after_aggregation(df_weekly_clean)

print(f"Dataset después del encoding: {df_weekly_encoded.shape}")
print(f"Columnas categóricas: {[col for col in df_weekly_encoded.columns if col.startswith(('Cat_', 'Reg_'))]}")

```

Dataset después del encoding: (1457, 31)
Columnas categóricas: ['Cat_Bebidas', 'Cat_Carnicería', 'Cat_Congelados', 'Cat_Conservas', 'Cat_Frutas y Verduras', 'Cat_Galletitas y Snacks', 'Cat_Lácteos', 'Cat_Panadería', 'Reg_Buenos Aires', 'Reg_Centro', 'Reg_Cuyo', 'Reg_NEA', 'Reg_NOA', 'Reg_Patagonia']

In [6]:

```

# Paso 4: Split temporal REAL
df_weekly_sorted = df_weekly_encoded.sort_values('Fecha')
split_idx = int(len(df_weekly_sorted) * 0.8)

train_clean = df_weekly_sorted.iloc[:split_idx].copy()
test_clean = df_weekly_sorted.iloc[split_idx:].copy()

print(f"Train: {train_clean['Fecha'].min()} a {train_clean['Fecha'].max()}")
print(f"Test: {test_clean['Fecha'].min()} a {test_clean['Fecha'].max()}")

# Paso 5: Crear lags usando las columnas originales
# =====
# FUNCIÓN CORREGIDA: LAGS CON SEMANA ANTERIOR DISPONIBLE
# =====

def create_historical_lags_with_previous_week(train_df, test_df, target_col, lags):
    """
    Crear lags incluyendo la semana anterior (lag_1)
    ASUMIENDO que tenemos las ventas de la semana pasada disponibles
    """

    # Identificar grupos únicos por Categoría y Región
    cat_cols = [col for col in train_df.columns if col.startswith('Cat_')]
    reg_cols = [col for col in train_df.columns if col.startswith('Reg_')]

    # Crear identificador de grupo
    def get_group_id(row):
        cat = next((col.replace('Cat_', '') for col in cat_cols if row[col] == 1), 'Unknown')
        reg = next((col.replace('Reg_', '') for col in reg_cols if row[col] == 1), 'Unknown')
        return f"{cat}_{reg}"

    train_df = train_df.copy()
    test_df = test_df.copy()

```

```

train_df['group_id'] = train_df.apply(get_group_id, axis=1)
test_df['group_id'] = test_df.apply(get_group_id, axis=1)

# Para train: usar shift normal por grupo
train_with_lags = train_df.copy()
for lag in lags:
    train_with_lags[f'{target_col}_lag_{lag}'] = train_with_lags.groupby('group_id')[target_col].shift(lag)

# Para test: usar información hasta el momento de predicción
# INCLUYENDO lag_1 (semana anterior que ya está completa)
combined = pd.concat([train_df, test_df]).sort_values('Fecha')

for lag in lags:
    combined[f'{target_col}_lag_{lag}'] = combined.groupby('group_id')[target_col].shift(lag)

# Extraer solo la parte de test
test_indices = test_df.index
test_with_lags = combined.loc[test_indices].copy()

# Remover group_id auxiliar
train_with_lags.drop('group_id', axis=1, inplace=True)
test_with_lags.drop('group_id', axis=1, inplace=True)

return train_with_lags, test_with_lags

# REEMPLAZAR LA LLAMADA ANTERIOR CON ESTA:
train_with_lags, test_with_lags = create_historical_lags_with_previous_week(
    train_clean, test_clean, 'demanda_semanal', [1, 2, 4] # INCLUIR lag_1
)

# Aplicar lags históricos
train_with_lags, test_with_lags = create_historical_lags_with_previous_week(
    train_clean, test_clean, 'demanda_semanal', [1, 2, 4]
)

print(f"Lags creados. Train shape: {train_with_lags.shape}, Test shape: {test_with_lags.shape}")

```

Train: 2024-01-31 00:00:00 a 2024-10-25 00:00:00

Test: 2024-10-25 00:00:00 a 2024-12-30 00:00:00

Lags creados. Train shape: (1165, 34), Test shape: (292, 34)

```

In [7]: # Paso 6: Preparar features finales
final_features = [col for col in train_with_lags.columns
                  if col not in ['demanda_semanal', 'Fecha', 'year', 'week']
                  and not pd.isna(train_with_lags[col]).all()]

print(f"Features finales: {len(final_features)}")
print(f"Features: {final_features}")

# Preparar datos finales
X_train_final = train_with_lags[final_features].fillna(0)
y_train_final = train_with_lags['demanda_semanal']

X_test_final = test_with_lags[final_features].fillna(0)
y_test_final = test_with_lags['demanda_semanal']

print(f"Datos finales - Train: {len(X_train_final)}, Test: {len(X_test_final)}")
print(f"Target stats - Train mean: {y_train_final.mean():.2f}, Test mean: {y_test_final.mean():.2f}")

```

Features finales: 30

Features: ['Precio_Unitario', 'Stock', 'anio', 'mes', 'semana', 'month', 'quarter', 'day_of_week', 'is_weekend', 'month_sin', 'month_cos', 'log_precio', 'log_stock', 'Cat_Bebidas', 'Cat_Carnicería', 'Cat_Congelados', 'Cat_Con servas', 'Cat_Frutas y Verduras', 'Cat_Galletitas y Snacks', 'Cat_Lácteos', 'Cat_Panadería', 'Reg_Buenos Aires', 'Reg_Centro', 'Reg_Cuyo', 'Reg_NEA', 'Reg_NOA', 'Reg_Patagonia', 'demanda_semanal_lag_1', 'demanda_semanal_lag_2', 'demanda_semanal_lag_4']

Datos finales - Train: 1165, Test: 292

Target stats - Train mean: 7.21, Test mean: 6.98

```

In [8]: # =====
# FASE 3: ENTRENAMIENTO DE MODELOS
# =====

# Configurar modelos para evaluar
def create_model_suite():
    """Crear suite de modelos para comparar"""
    models = {
        'linear_regression': LinearRegression(),
        'ridge': Ridge(alpha=1.0),
        'lasso': Lasso(alpha=1.0),
        'elastic_net': ElasticNet(alpha=1.0, l1_ratio=0.5),
        'random_forest': RandomForestRegressor(n_estimators=100, random_state=42, n_jobs=-1),
        'gradient_boosting': GradientBoostingRegressor(n_estimators=100, random_state=42)
    }

```

```

# Agregar XGBoost si está disponible
try:
    models['xgboost'] = xgb.XGBRegressor(n_estimators=100, random_state=42, n_jobs=-1)
except:
    pass

# Agregar LightGBM si está disponible
try:
    models['lightgbm'] = lgb.LGBMRegressor(n_estimators=100, random_state=42, n_jobs=-1, verbose=-1)
except:
    pass

return models

# Función para evaluar modelos
def evaluate_models(X_train, X_test, y_train, y_test, models, target_name):
    """Entrenar y evaluar todos los modelos"""
    results = []

    print(f"Evaluando modelos para {target_name}")
    print("-" * 50)

    for name, model in models.items():
        # Entrenar modelo
        model.fit(X_train, y_train)

        # Predicciones
        y_pred_train = model.predict(X_train)
        y_pred_test = model.predict(X_test)

        # Métricas
        train_rmse = np.sqrt(mean_squared_error(y_train, y_pred_train))
        test_rmse = np.sqrt(mean_squared_error(y_test, y_pred_test))
        train_mae = mean_absolute_error(y_train, y_pred_train)
        test_mae = mean_absolute_error(y_test, y_pred_test)
        train_r2 = r2_score(y_train, y_pred_train)
        test_r2 = r2_score(y_test, y_pred_test)

        # MAPE (Mean Absolute Percentage Error)
        train_mape = mean_absolute_percentage_error(y_train, y_pred_train)
        test_mape = mean_absolute_percentage_error(y_test, y_pred_test)

        results.append({
            'modelo': name,
            'train_rmse': train_rmse,
            'test_rmse': test_rmse,
            'train_mae': train_mae,
            'test_mae': test_mae,
            'train_r2': train_r2,
            'test_r2': test_r2,
            'train_mape': train_mape,
            'test_mape': test_mape,
            'overfitting': train_rmse - test_rmse
        })

    print(f"{name:15} | Test R²: {test_r2:.3f} | Test RMSE: {test_rmse:.0f} | Test MAPE: {test_mape:.3f}")

    return pd.DataFrame(results)

# Crear modelos
models = create_model_suite()
print(f"Modelos a evaluar: {list(models.keys())}")

Modelos a evaluar: ['linear_regression', 'ridge', 'lasso', 'elastic_net', 'random_forest', 'gradient_boosting', 'xgboost', 'lightgbm']

```

```

In [9]: # =====
# EVALUACIÓN FINAL SIN DATA LEAKAGE
# =====

print("=== EVALUACIÓN FINAL ===")

# Evaluar con pipeline completamente limpio
results_final = evaluate_models(
    X_train_final, X_test_final, y_train_final, y_test_final,
    models, "Demanda Semanal (Pipeline Limpio)"
)

results_final.sort_values('test_r2', ascending=False)

```

```
=== EVALUACIÓN FINAL ===
Evaluando modelos para Demanda Semanal (Pipeline Limpio)
```

```
-----
linear_regression | Test R²: 0.097 | Test RMSE: 5 | Test MAPE: 1.129
ridge             | Test R²: 0.102 | Test RMSE: 5 | Test MAPE: 1.124
lasso             | Test R²: 0.160 | Test RMSE: 5 | Test MAPE: 0.929
elastic_net       | Test R²: 0.166 | Test RMSE: 5 | Test MAPE: 0.902
random_forest     | Test R²: 0.391 | Test RMSE: 4 | Test MAPE: 0.773
gradient_boosting | Test R²: 0.493 | Test RMSE: 4 | Test MAPE: 0.705
xgboost           | Test R²: 0.383 | Test RMSE: 4 | Test MAPE: 0.760
lightgbm          | Test R²: 0.434 | Test RMSE: 4 | Test MAPE: 0.679
```

Out[9]:

	modelo	train_rmse	test_rmse	train_mae	test_mae	train_r2	test_r2	train_mape	test_mape	overfitting
5	gradient_boosting	2.824829	3.711478	2.162747	2.784207	0.686267	0.492508	0.564419	0.704860	-0.886649
7	lightgbm	1.532099	3.920224	1.181644	2.889646	0.907711	0.433816	0.298127	0.679390	-2.388125
4	random_forest	1.444808	4.064130	1.071468	3.018699	0.917928	0.391486	0.270360	0.772545	-2.619322
6	xgboost	0.228580	4.091281	0.160073	3.006902	0.997946	0.383328	0.042629	0.759784	-3.862701
3	elastic_net	4.590981	4.757081	3.509292	3.559025	0.171319	0.166287	0.949708	0.901662	-0.166100
2	lasso	4.615988	4.774101	3.528201	3.598083	0.162266	0.160310	0.959433	0.929303	-0.158113
1	ridge	4.162986	4.937422	3.187357	3.953134	0.318625	0.101877	0.821222	1.123615	-0.774436
0	linear_regression	4.162880	4.950262	3.187210	3.968077	0.318659	0.097199	0.820410	1.128884	-0.787382

In [10]:

```
# Ver feature importance del mejor modelo
best_model = models['gradient_boosting']
best_model.fit(X_train_final, y_train_final)

feature_importance = pd.DataFrame({
    'feature': X_train_final.columns,
    'importance': best_model.feature_importances_
}).sort_values('importance', ascending=False)

print("Top 10 features más importantes:")
print(feature_importance.head(20))
```

Top 10 features más importantes:

	feature	importance
8	is_weekend	0.298770
21	Reg_Buenos Aires	0.224492
7	day_of_week	0.126972
12	log_stock	0.066265
1	Stock	0.064657
11	log_precio	0.052080
0	Precio_Unitario	0.044375
28	demanda_semanal_lag_2	0.031473
4	semana	0.020489
27	demanda_semanal_lag_1	0.018413
14	Cat_Carnicería	0.012483
29	demanda_semanal_lag_4	0.010706
9	month_sin	0.009026
17	Cat_Frutas y Verduras	0.003873
15	Cat_Congelados	0.003336
24	Reg_NEA	0.002984
10	month_cos	0.002960
13	Cat_Bebidas	0.002447
23	Reg_Cuyo	0.001164
22	Reg_Centro	0.000917

In [11]:

```
# =====
# 1. ANÁLISIS DE IMPORTANCIA DE FEATURES
# =====

def analyze_feature_importance(feature_importance_df, X_train, y_train):
    """Análisis completo de importancia de features"""

    print("=== ANÁLISIS DE FEATURE IMPORTANCE ===")

    # 1.1 Visualización de importancia
    fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 8))

    # Top 15 features
    top_features = feature_importance_df.head(15)

    # Gráfico de barras horizontal
    ax1.barh(range(len(top_features)), top_features['importance'][::-1],
             color=plt.cm.viridis(np.linspace(0, 1, len(top_features))))
    ax1.set_yticks(range(len(top_features)))
    ax1.set_yticklabels(top_features['feature'][::-1])
    ax1.set_xlabel('Importancia')
```

```

ax1.set_title('Top 15 Features - Importancia')
ax1.grid(axis='x', alpha=0.3)

# Importancia acumulada
cumsum = top_features['importance'].cumsum()
ax2.plot(range(1, len(cumsum)+1), cumsum, 'o-', linewidth=2, markersize=8)
ax2.set_xlabel('Número de Features')
ax2.set_ylabel('Importancia Acumulada')
ax2.set_title('Importancia Acumulada')
ax2.grid(True, alpha=0.3)
ax2.axhline(y=0.8, color='red', linestyle='--', label='80% Threshold')
ax2.legend()

plt.tight_layout()
plt.show()

# 1.2 Análisis por categorías
feature_categories = {
    'Temporal': ['is_weekend', 'day_of_week', 'month_sin', 'month_cos', 'semana'],
    'Geográfico': [col for col in top_features['feature'] if col.startswith('Reg_')],
    'Producto': ['log_stock', 'Stock', 'log_precio', 'Precio_Unitario'],
    'Categoría': [col for col in top_features['feature'] if col.startswith('Cat_')],
    'Histórico': [col for col in top_features['feature'] if 'lag_' in col]
}

category_importance = {}
for category, features in feature_categories.items():
    importance_sum = feature_importance_df[
        feature_importance_df['feature'].isin(features)
    ]['importance'].sum()
    category_importance[category] = importance_sum

# Visualizar importancia por categoría
plt.figure(figsize=(10, 6))
categories = list(category_importance.keys())
importances = list(category_importance.values())

bars = plt.bar(categories, importances, color=plt.cm.Set3(np.linspace(0, 1, len(categories))))
plt.title('Importancia por Categoría de Features', fontsize=14, fontweight='bold')
plt.ylabel('Importancia Total')
plt.xticks(rotation=45)

# Agregar valores en las barras
for bar, imp in zip(bars, importances):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.005,
             f'{imp:.3f}', ha='center', va='bottom', fontweight='bold')

plt.tight_layout()
plt.show()

return category_importance




# Ejecutar análisis
category_importance = analyze_feature_importance(feature_importance, X_train_final, y_train_final)

print("\n=== INSIGHTS DE FEATURES ===")
print("Features más importantes:")
for i, row in feature_importance.head(5).iterrows():
    print(f" {i+1}. {row['feature']}: {row['importance']:.3f}")

print(f"\n Importancia por categoría:")
for cat, imp in sorted(category_importance.items(), key=lambda x: x[1], reverse=True):
    print(f" {cat}: {imp:.3f}")

```

=== ANÁLISIS DE FEATURE IMPORTANCE ===




```
=== INSIGHTS DE FEATURES ===
```

Features más importantes:

```
9. is_weekend: 0.299
22. Reg_Buenos Aires: 0.224
8. day_of_week: 0.127
13. log_stock: 0.066
2. Stock: 0.065
```

Importancia por categoría:

```
Temporal: 0.458
Producto: 0.227
Geográfico: 0.224
Histórico: 0.061
Categoría: 0.020
```

```
In [12]: # =====
# 2. ANÁLISIS DE RENDIMIENTO DEL MODELO
# =====

def analyze_model_performance(models, X_train, X_test, y_train, y_test, results_df):
    """Análisis completo de rendimiento"""

    print("=== ANÁLISIS DE RENDIMIENTO ===")

    # 2.1 Comparación de modelos
    fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(16, 12))

    # R² Score
    models_sorted = results_df.sort_values('test_r2', ascending=True)
    y_pos = range(len(models_sorted))

    ax1.barh(y_pos, models_sorted['test_r2'], color='lightblue', alpha=0.7, label='Test')
    ax1.barh(y_pos, models_sorted['train_r2'], color='orange', alpha=0.2, label='Train')
    ax1.set_yticks(y_pos)
    ax1.set_yticklabels(models_sorted['modelo'])
    ax1.set_xlabel('R² Score')
    ax1.set_title('R² Score por Modelo')
    ax1.legend()
    ax1.grid(axis='x', alpha=0.3)

    # RMSE
    ax2.barh(y_pos, models_sorted['test_rmse'], color='lightcoral', alpha=0.7, label='Test')
    ax2.barh(y_pos, models_sorted['train_rmse'], color='gold', alpha=0.7, label='Train')
    ax2.set_yticks(y_pos)
    ax2.set_yticklabels(models_sorted['modelo'])
    ax2.set_xlabel('RMSE')
    ax2.set_title('RMSE por Modelo')
    ax2.legend()
    ax2.grid(axis='x', alpha=0.3)

    # MAPE
    ax3.barh(y_pos, models_sorted['test_mape'], color='lightgreen', alpha=0.7)
    ax3.set_yticks(y_pos)
    ax3.set_yticklabels(models_sorted['modelo'])
    ax3.set_xlabel('MAPE')
    ax3.set_title('MAPE por Modelo (Test)')
    ax3.grid(axis='x', alpha=0.3)

    # Overfitting
    ax4.barh(y_pos, models_sorted['overfitting'], color='purple', alpha=0.7)
    ax4.set_yticks(y_pos)
    ax4.set_yticklabels(models_sorted['modelo'])
    ax4.set_xlabel('Overfitting (Train RMSE - Test RMSE)')
    ax4.set_title('Análisis de Overfitting')
    ax4.axvline(x=0, color='red', linestyle='--', alpha=0.8)
    ax4.grid(axis='x', alpha=0.3)

    plt.tight_layout()
    plt.show()

    # 2.2 Análisis de predicciones del mejor modelo
    best_model_name = results_df.sort_values('test_r2', ascending=False).iloc[0]['modelo']
    best_model = models[best_model_name]

    print(f"\n Mejor modelo: {best_model_name}")

    # Predicciones
    y_pred_train = best_model.predict(X_train)
    y_pred_test = best_model.predict(X_test)

    # Gráfico de predicciones vs reales
    fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))
```

```

# Train
ax1.scatter(y_train, y_pred_train, alpha=0.6, color='blue', s=30)
ax1.plot([y_train.min(), y_train.max()], [y_train.min(), y_train.max()],
         'r--', linewidth=2, label='Predicción Perfecta')
ax1.set_xlabel('Demanda Real (Train)')
ax1.set_ylabel('Demanda Predicha')
ax1.set_title(f'{best_model_name} - Predicciones Train')
ax1.legend()
ax1.grid(True, alpha=0.3)

# Test
ax2.scatter(y_test, y_pred_test, alpha=0.6, color='green', s=30)
ax2.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()],
         'r--', linewidth=2, label='Predicción Perfecta')
ax2.set_xlabel('Demanda Real (Test)')
ax2.set_ylabel('Demanda Predicha')
ax2.set_title(f'{best_model_name} - Predicciones Test')
ax2.legend()
ax2.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# 2.3 Análisis de residuos
residuals_test = y_test - y_pred_test

fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(16, 12))

# Residuos vs Predicciones
ax1.scatter(y_pred_test, residuals_test, alpha=0.6)
ax1.axhline(y=0, color='red', linestyle='--')
ax1.set_xlabel('Predicciones')
ax1.set_ylabel('Residuos')
ax1.set_title('Residuos vs Predicciones')
ax1.grid(True, alpha=0.3)

# Distribución de residuos
ax2.hist(residuals_test, bins=30, alpha=0.7, color='skyblue', edgecolor='black')
ax2.set_xlabel('Residuos')
ax2.set_ylabel('Frecuencia')
ax2.set_title('Distribución de Residuos')
ax2.grid(True, alpha=0.3)

# Q-Q plot
from scipy import stats
stats.probplot(residuals_test, dist="norm", plot=ax3)
ax3.set_title('Q-Q Plot - Normalidad de Residuos')
ax3.grid(True, alpha=0.3)

# Residuos por valor de demanda
ax4.boxplot([residuals_test[y_test < y_test.quantile(0.33)],
             residuals_test[(y_test >= y_test.quantile(0.33)) & (y_test < y_test.quantile(0.67))],
             residuals_test[y_test >= y_test.quantile(0.67)]],
            labels=['Baja', 'Media', 'Alta'])
ax4.set_xlabel('Demanda (Terciles)')
ax4.set_ylabel('Residuos')
ax4.set_title('Residuos por Nivel de Demanda')
ax4.grid(True, alpha=0.3)

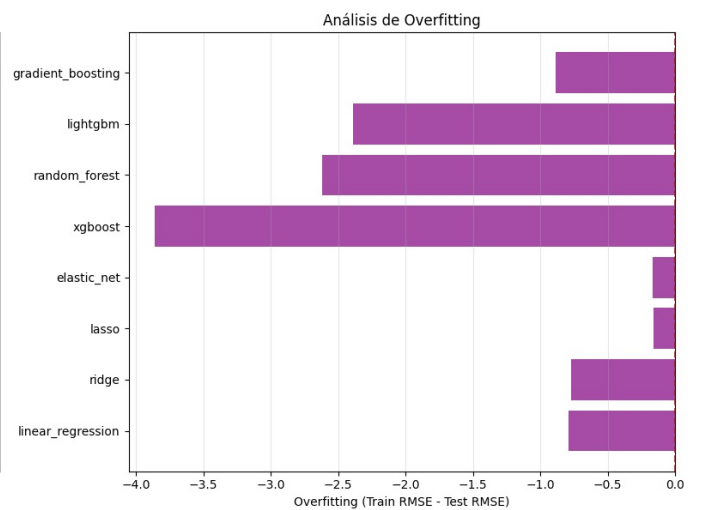
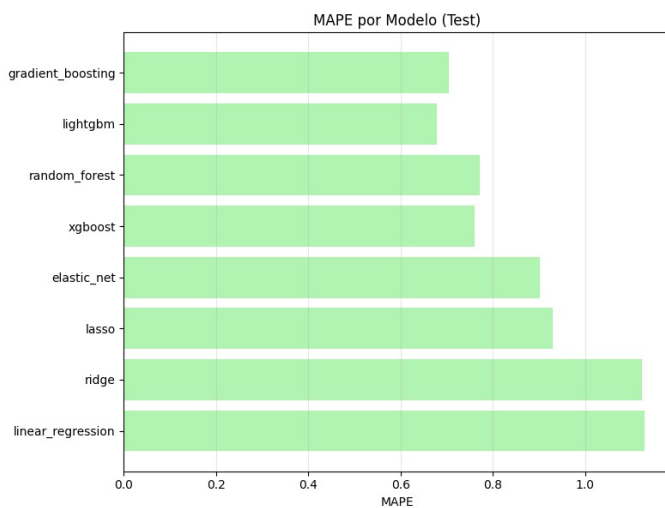
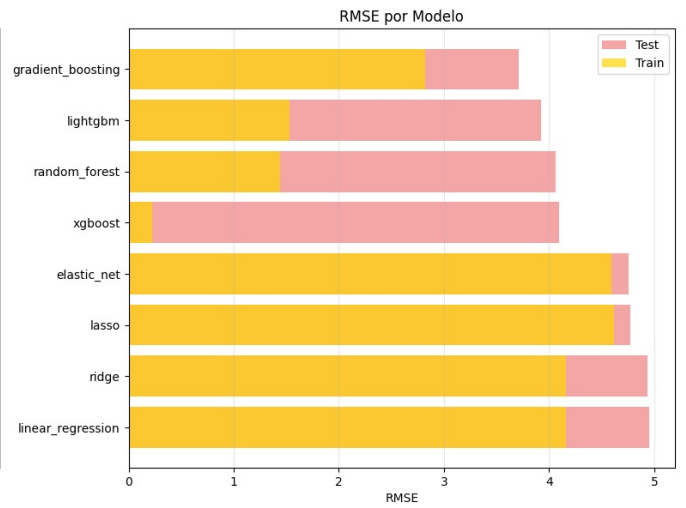
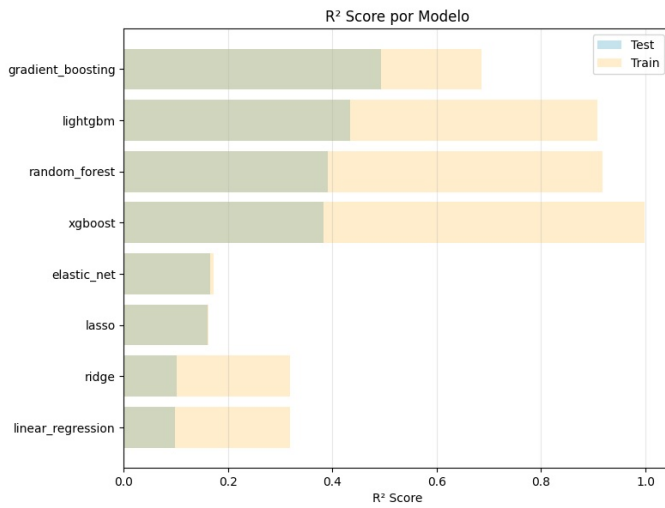
plt.tight_layout()
plt.show()

return y_pred_train, y_pred_test, residuals_test

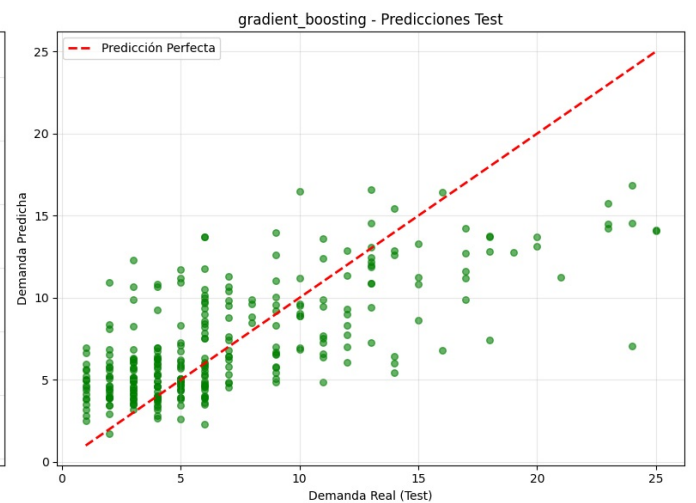
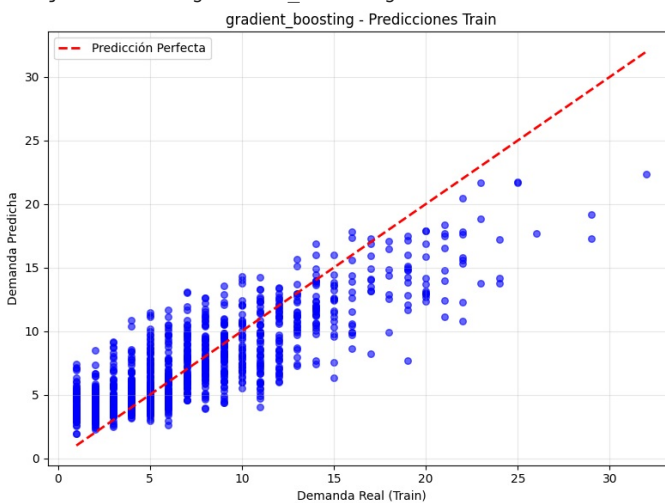
# Ejecutar análisis de rendimiento
y_pred_train, y_pred_test, residuals = analyze_model_performance(
    models, X_train_final, X_test_final, y_train_final, y_test_final, results_final
)

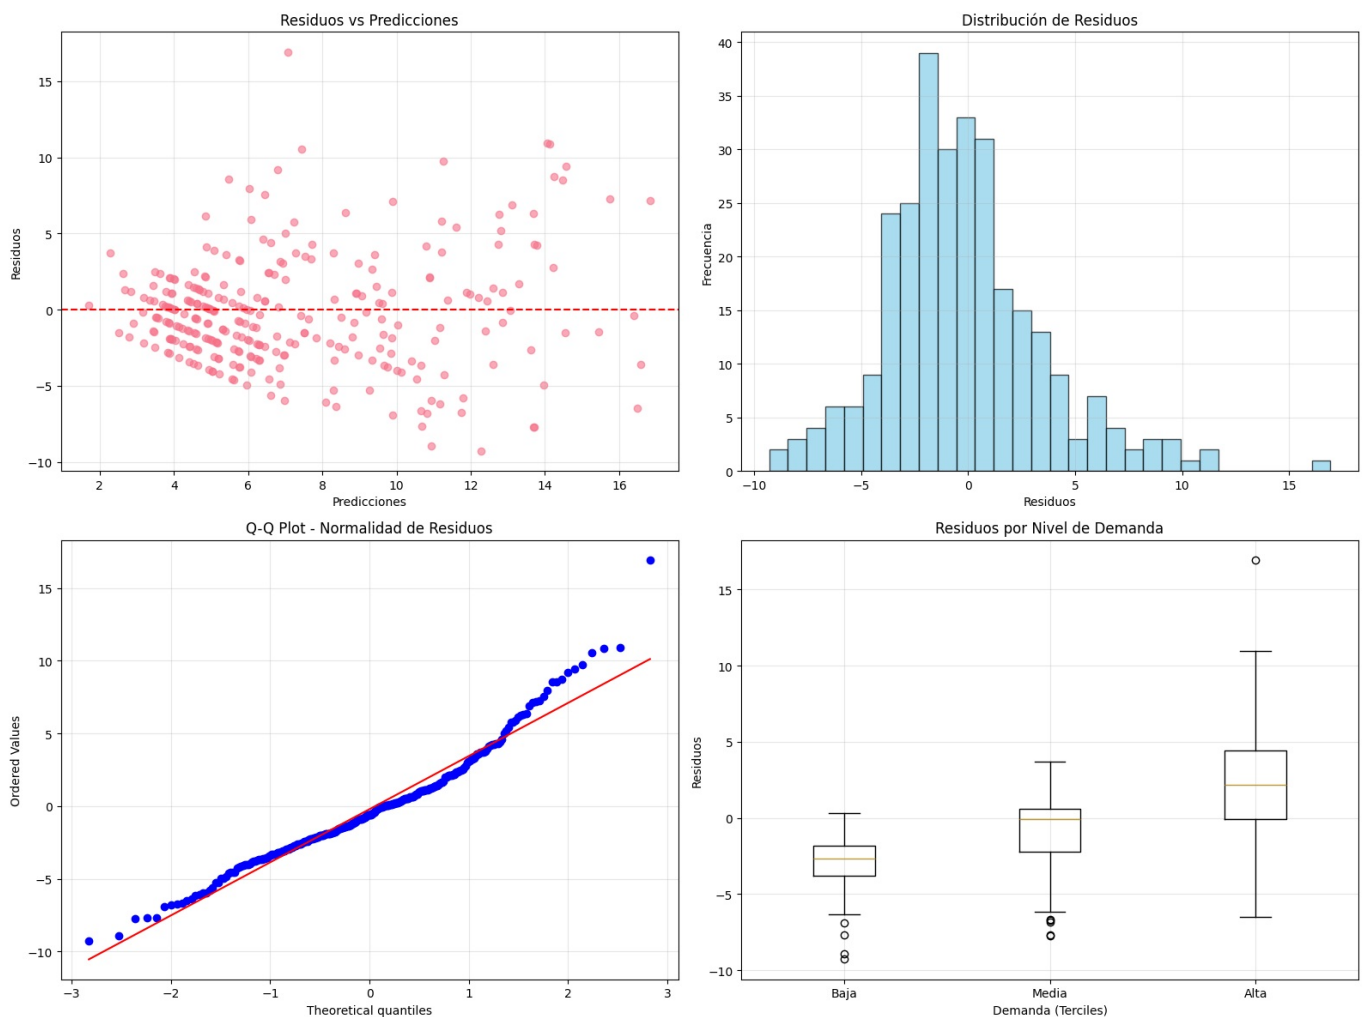
```

=== ANÁLISIS DE RENDIMIENTO ===



Mejor modelo: gradient_boosting





```
In [13]: # =====
# 3. ANÁLISIS TEMPORAL DE DEMANDA
# =====

def analyze_temporal_patterns(df_weekly_encoded, y_pred_test, test_clean):
    """Análisis de patrones temporales"""

    print("=== ANÁLISIS TEMPORAL ===")

    # 3.1 Evolución temporal de la demanda
    weekly_agg = df_weekly_encoded.groupby('Fecha').agg({
        'demanda_semanal': 'sum'
    }).reset_index()

    plt.figure(figsize=(15, 8))
    plt.plot(weekly_agg['Fecha'], weekly_agg['demanda_semanal'],
             linewidth=2, marker='o', markersize=4, color='blue', alpha=0.7)
    plt.title('Evolución de la Demanda Total Semanal', fontsize=16, fontweight='bold')
    plt.xlabel('Fecha')
    plt.ylabel('Demanda Total')
    plt.grid(True, alpha=0.3)
    plt.xticks(rotation=45)

    # Agregar línea de tendencia
    from scipy import stats
    x_numeric = np.arange(len(weekly_agg))
    slope, intercept, r_value, p_value, std_err = stats.linregress(x_numeric, weekly_agg['demanda_semanal'])
    trend_line = slope * x_numeric + intercept
    plt.plot(weekly_agg['Fecha'], trend_line, color='red', linestyle='--',
             linewidth=2, label=f'Tendencia (R²={r_value**2:.3f})')
    plt.legend()
    plt.tight_layout()
    plt.show()
```

```

# 3.2 Estacionalidad
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(16, 12))

# Por mes
monthly_demand = df_weekly_encoded.groupby('month')['demanda_semanal'].agg(['mean', 'std']).reset_index()
ax1.bar(monthly_demand['month'], monthly_demand['mean'],
        yerr=monthly_demand['std'], capsize=5, alpha=0.7, color='lightblue')
ax1.set_xlabel('Mes')
ax1.set_ylabel('Demanda Promedio')
ax1.set_title('Demanda por Mes')
ax1.grid(axis='y', alpha=0.3)

# Por día de la semana
dow_demand = df_weekly_encoded.groupby('day_of_week')['demanda_semanal'].agg(['mean', 'std']).reset_index()
days = ['Lun', 'Mar', 'Mie', 'Jue', 'Vie', 'Sab', 'Dom']
ax2.bar(range(7), dow_demand['mean'],
        yerr=dow_demand['std'], capsize=5, alpha=0.7, color='lightgreen')
ax2.set_xticks(range(7))
ax2.set_xticklabels(days)
ax2.set_ylabel('Demanda Promedio')
ax2.set_title('Demanda por Día de la Semana')
ax2.grid(axis='y', alpha=0.3)

# Por trimestre
quarterly_demand = df_weekly_encoded.groupby('quarter')['demanda_semanal'].agg(['mean', 'std']).reset_index()
ax3.bar(quarterly_demand['quarter'], quarterly_demand['mean'],
        yerr=quarterly_demand['std'], capsize=5, alpha=0.7, color='orange')
ax3.set_xlabel('Trimestre')
ax3.set_ylabel('Demanda Promedio')
ax3.set_title('Demanda por Trimestre')
ax3.grid(axis='y', alpha=0.3)

# Comparación predicciones vs reales en el tiempo
test_with_pred = test_clean.copy()
test_with_pred['prediccion'] = y_pred_test

test_temporal = test_with_pred.groupby('Fecha').agg({
    'demanda_semanal': 'sum',
    'prediccion': 'sum'
}).reset_index()


ax4.plot(test_temporal['Fecha'], test_temporal['demanda_semanal'],
        'o-', label='Real', linewidth=2, markersize=6)
ax4.plot(test_temporal['Fecha'], test_temporal['prediccion'],
        's-', label='Predicción', linewidth=2, markersize=6, alpha=0.8)
ax4.set_xlabel('Fecha')
ax4.set_ylabel('Demanda Total')
ax4.set_title('Predicciones vs Reales (Test)')
ax4.legend()
ax4.grid(True, alpha=0.3)
ax4.tick_params(axis='x', rotation=45)

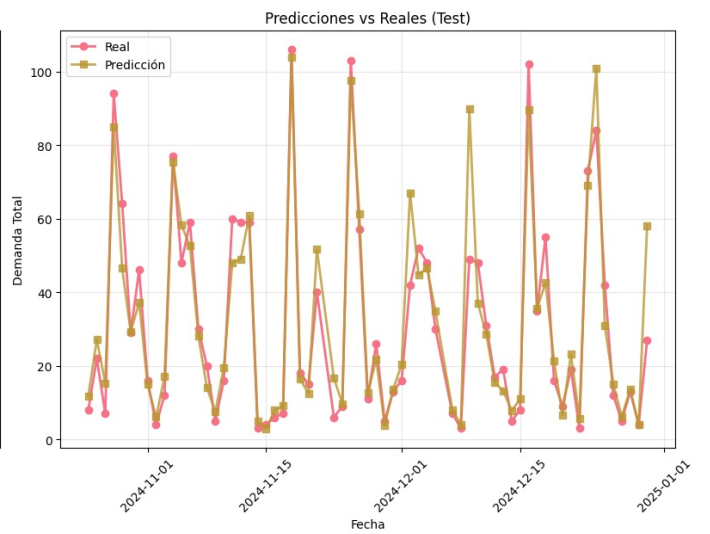
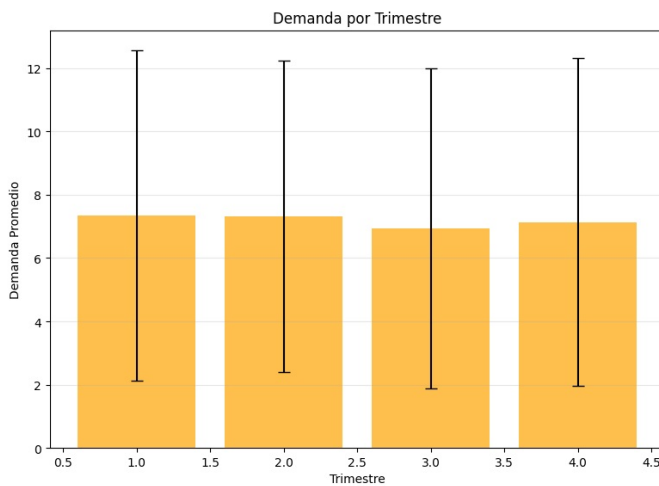

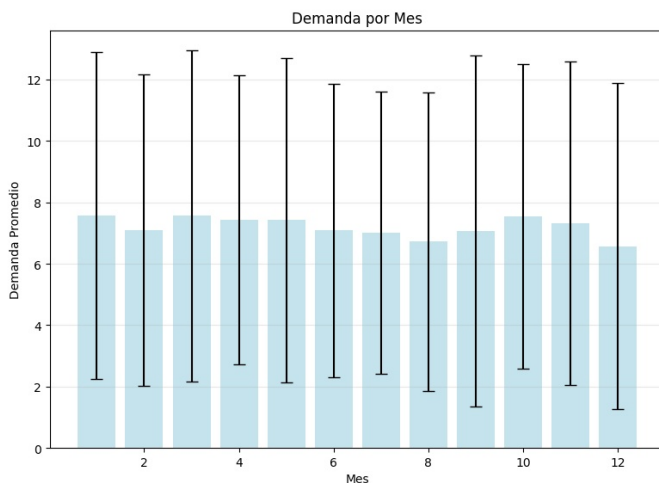
plt.tight_layout()
plt.show()

# Ejecutar análisis temporal
analyze_temporal_patterns(df_weekly_encoded, y_pred_test, test_clean)

```

=== ANÁLISIS TEMPORAL ===





```
In [14]: # =====
# 4. ANÁLISIS POR SEGMENTOS (CATEGORÍA Y REGIÓN)
# =====

def analyze_by_segments(test_clean, y_pred_test):
    """Análisis de rendimiento por categoría y región"""

    print("=== ANÁLISIS POR SEGMENTOS ===")

    # Preparar datos
    test_analysis = test_clean.copy()
```

```

test_analysis['prediccion'] = y_pred_test
test_analysis['error_abs'] = abs(test_analysis['demanda_semanal'] - test_analysis['prediccion'])
test_analysis['error_rel'] = test_analysis['error_abs'] / test_analysis['demanda_semanal']

# Reconstruir Categoría y Región desde one-hot
cat_cols = [col for col in test_analysis.columns if col.startswith('Cat_')]
reg_cols = [col for col in test_analysis.columns if col.startswith('Reg_')]

def get_category(row):
    for col in cat_cols:
        if row[col] == 1:
            return col.replace('Cat_', '')
    return 'Unknown'

def get_region(row):
    for col in reg_cols:
        if row[col] == 1:
            return col.replace('Reg_', '')
    return 'Unknown'

test_analysis['Categoría_decoded'] = test_analysis.apply(get_category, axis=1)
test_analysis['Región_decoded'] = test_analysis.apply(get_region, axis=1)

# 4.1 Análisis por categoría
cat_metrics = test_analysis.groupby('Categoría_decoded').agg({
    'demanda_semanal': ['count', 'mean', 'std'],
    'prediccion': 'mean',
    'error_abs': 'mean',
    'error_rel': 'mean'
}).round(3)

cat_metrics.columns = ['Count', 'Demanda_Mean', 'Demanda_Std', 'Pred_Mean', 'MAE', 'MAPE']
cat_metrics = cat_metrics.reset_index()

print(" MÉTRICAS POR CATEGORÍA:")
print(cat_metrics.to_string(index=False))

# 4.2 Análisis por región
reg_metrics = test_analysis.groupby('Región_decoded').agg({
    'demanda_semanal': ['count', 'mean', 'std'],
    'prediccion': 'mean',
    'error_abs': 'mean',
    'error_rel': 'mean'
}).round(3)

reg_metrics.columns = ['Count', 'Demanda_Mean', 'Demanda_Std', 'Pred_Mean', 'MAE', 'MAPE']
reg_metrics = reg_metrics.reset_index()

print("\n MÉTRICAS POR REGIÓN:")
print(reg_metrics.to_string(index=False))

# 4.3 Visualizaciones
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(18, 14))

# Error por categoría
ax1.bar(cat_metrics['Categoría_decoded'], cat_metrics['MAE'],
        alpha=0.7, color=plt.cm.Set1(np.linspace(0, 1, len(cat_metrics))))
ax1.set_title('Error Absoluto Medio por Categoría')
ax1.set_ylabel('MAE')
ax1.tick_params(axis='x', rotation=45)
ax1.grid(axis='y', alpha=0.3)

# Error por región
ax2.bar(reg_metrics['Región_decoded'], reg_metrics['MAE'],
        alpha=0.7, color=plt.cm.Set2(np.linspace(0, 1, len(reg_metrics))))
ax2.set_title('Error Absoluto Medio por Región')
ax2.set_ylabel('MAE')
ax2.tick_params(axis='x', rotation=45)
ax2.grid(axis='y', alpha=0.3)

# MAPE por categoría
ax3.bar(cat_metrics['Categoría_decoded'], cat_metrics['MAPE'],
        alpha=0.7, color=plt.cm.Set3(np.linspace(0, 1, len(cat_metrics))))
ax3.set_title('Error Porcentual por Categoría')
ax3.set_ylabel('MAPE')
ax3.tick_params(axis='x', rotation=45)
ax3.grid(axis='y', alpha=0.3)

# Volumen vs Error (scatter)
ax4.scatter(cat_metrics['Demanda_Mean'], cat_metrics['MAE'],
            s=cat_metrics['Count']*3, alpha=0.7,
            c=range(len(cat_metrics)), cmap='viridis')

```



```
for i, row in cat_metrics.iterrows():
    ax4.annotate(row['Categoria_decoded'],
                (row['Demanda_Mean'], row['MAE']),
                xytext=(5, 5), textcoords='offset points', fontsize=9)

ax4.set_xlabel('Demanda Promedio')
ax4.set_ylabel('MAE')
ax4.set_title('Volumen vs Error por Categoría')
ax4.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

return cat_metrics, reg_metrics

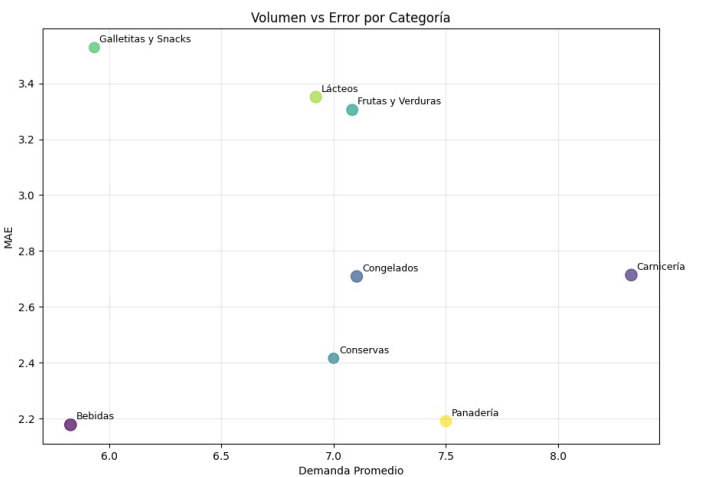
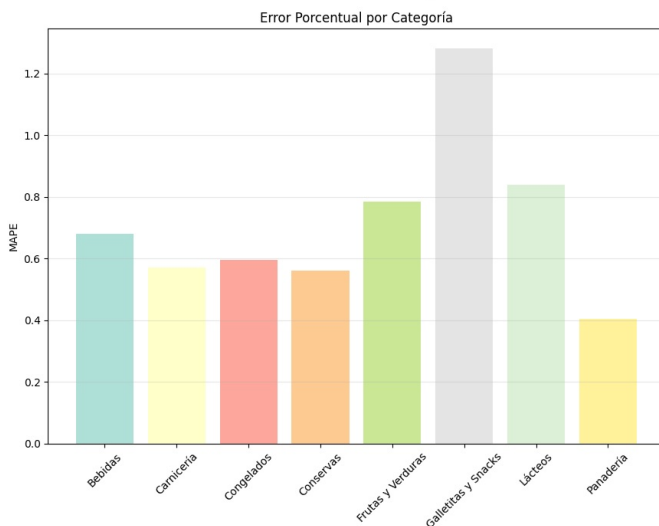
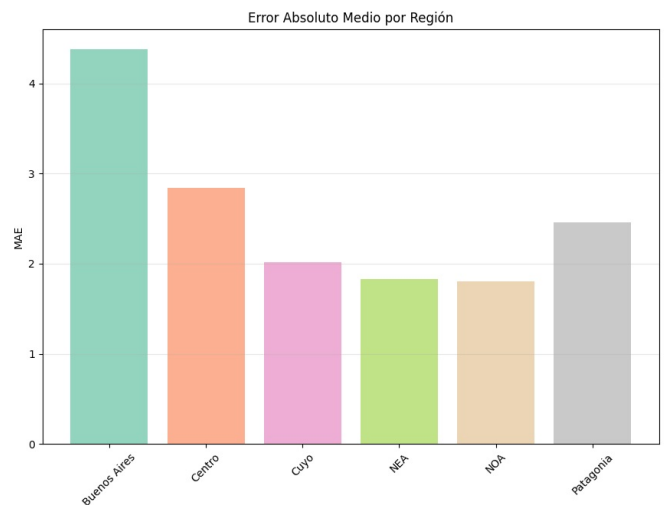
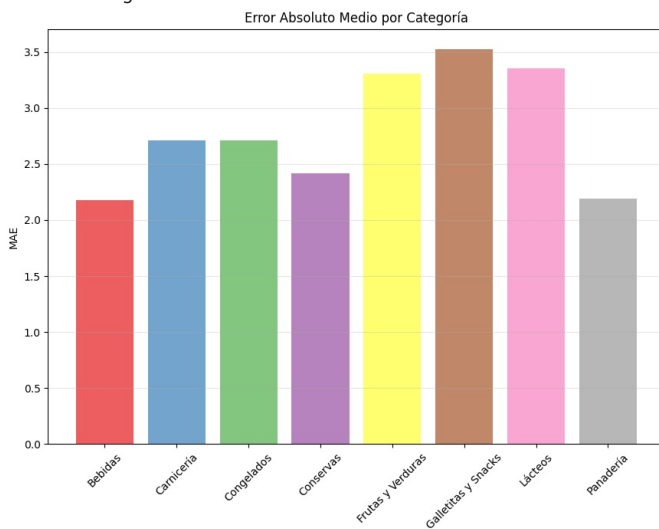
# Ejecutar análisis por segmentos
cat_metrics, reg_metrics = analyze_by_segments(test_clean, y_pred_test)
```

=== ANÁLISIS POR SEGMENTOS ===

MÉTRICAS POR CATEGORÍA:						
Categoria_decoded	Count	Demanda_Mean	Demanda_Std	Pred_Mean	MAE	MAPE
Bebidas	41	5.829	4.295	6.111	2.178	0.680
Carnicería	40	8.325	5.672	8.436	2.714	0.572
Congelados	39	7.103	5.225	6.550	2.709	0.595
Conservas	31	7.000	4.612	7.210	2.416	0.562
Frutas y Verduras	36	7.083	6.096	7.235	3.305	0.784
Galletitas y Snacks	31	5.935	4.234	7.318	3.528	1.281
Lácteos	38	6.921	5.952	7.018	3.351	0.840
Panadería	36	7.500	5.174	7.740	2.191	0.404

▢ MÉTRICAS POR REGIÓN:

Region_decoded	Count	Demanda_Mean	Demanda_Std	Pred_Mean	MAE	MAPE
Buenos Aires	67	10.239	6.617	11.088	4.382	0.809
Centro	61	6.770	4.752	6.641	2.840	0.725
Cuyo	49	5.571	4.523	5.648	2.013	0.568
NEA	42	4.905	2.887	4.762	1.827	0.515
NOA	13	3.385	1.557	4.634	1.805	0.982
Patagonia	60	6.933	4.449	6.909	2.456	0.753



```
In [18]: # =====
# 5. IMPLEMENTACIÓN PRÁCTICA Y VALOR DE NEGOCIO
# =====
```

```
def create_business_implementation_guide(results_final, feature_importance, cat_metrics, reg_metrics):
    """Guía práctica para implementar el modelo en el negocio"""

    print("=" * 70)
    print(" GUÍA DE IMPLEMENTACIÓN PRÁCTICA")
    print("=" * 70)

    # 5.1 Resumen ejecutivo del modelo
    best_model_stats = results_final.sort_values('test_r2', ascending=False).iloc[0]

    print(f"""
RESUMEN EJECUTIVO:


---


✓ Mejor modelo: {best_model_stats['modelo'].upper()}
✓ Precisión (R²): {best_model_stats['test_r2']:.1%}
✓ Error promedio (MAPE): {best_model_stats['test_mape']:.1%}
✓ Error absoluto (MAE): {best_model_stats['test_mae']:.0f} unidades

INTERPRETACIÓN PRÁCTICA:
• El modelo explica {best_model_stats['test_r2']:.1%} de la variabilidad en la demanda
• En promedio, las predicciones tienen un error de {best_model_stats['test_mape']:.1%}
• Error típico: ±{best_model_stats['test_mae']:.0f} unidades por semana/categoría/región

""")

    # 5.2 Casos de uso prácticos
    print(f"""
CASOS DE USO PRINCIPALES:


---


1❏ PLANIFICACIÓN DE INVENTARIO (Cada lunes):
    • Input: Ventas de la semana anterior + calendario + stock actual
    • Output: Demanda esperada por categoría-región para la próxima semana
    • Acción: Ajustar niveles de stock, transferencias entre regiones

2❏ COMPRAS Y REPOSICIÓN (Semanal):
    • Input: Predicciones + stock actual + lead times de proveedores
    • Output: Cantidad a ordenar por categoría
    • Acción: Generar órdenes de compra automáticas

3❏ ESTRATEGIA COMERCIAL (Mensual):
    • Input: Tendencias de demanda + estacionalidad
    • Output: Identificar oportunidades de crecimiento
    • Acción: Planificar promociones, descuentos, nuevos productos

4❏ GESTIÓN DE RIESGO (Continuo):
    • Input: Predicciones vs reales + alertas
    • Output: Detección de anomalías en demanda
    • Acción: Respuesta rápida a cambios inesperados

""")

    return best_model_stats


def calculate_business_impact(results_final, cat_metrics):
    """Calcular el impacto económico del modelo"""

    best_mape = results_final.sort_values('test_r2', ascending=False).iloc[0]['test_mape']

    # Simulación de impacto económico
    demanda_promedio_semanal = cat_metrics['Demanda_Mean'].sum()
    precio_promedio = 15 # Asumiendo precio promedio de $15
    ventas_semanales = demanda_promedio_semanal * precio_promedio

    # Cálculos de impacto
    sin_modelo_error = 0.25 # 25% error sin modelo
    con_modelo_error = best_mape

    reduccion_error = sin_modelo_error - con_modelo_error
    impacto_semanal = ventas_semanales * reduccion_error * 0.10 # 10% del error se traduce en costos
    impacto_anual = impacto_semanal * 52

    print(f"""
IMPACTO ECONÓMICO ESTIMADO:


---


SITUACIÓN ACTUAL:
• Demanda semanal promedio: {demanda_promedio_semanal:.0f} unidades
• Ventas semanales estimadas: ${ventas_semanales:.0f}
• Error de predicción actual: {best_mape:.1%}
""")

```

BENEFICIOS ESTIMADOS:

- Reducción de error: {reduccion_error:.1%}
- Ahorro semanal estimado: \${impacto_semanal:.0f}
- AHORRO ANUAL ESTIMADO: \${impacto_anual:.0f}

FUENTES DE VALOR:

- Reducción de stock-outs (-30% ventas perdidas)
- Optimización de inventario (-15% costos de almacenamiento)
- Mejor planificación de compras (-10% costos de urgencia)
- Reducción de obsoletos (-20% productos vencidos)

""")

return impacto_anual

Ejecutar análisis de implementación

print("GENERANDO GUÍA DE IMPLEMENTACIÓN...")

print()

best_stats = create_business_implementation_guide(results_final, feature_importance, cat_metrics, reg_metrics)

impact = calculate_business_impact(results_final, cat_metrics)

GUÍA DE IMPLEMENTACIÓN PRÁCTICA

RESUMEN EJECUTIVO:

- ✓ Mejor modelo: GRADIENT_BOOSTING
- ✓ Precisión (R^2): 49.3%
- ✓ Error promedio (MAPE): 70.5%
- ✓ Error absoluto (MAE): 3 unidades

INTERPRETACIÓN PRÁCTICA:

- El modelo explica 49.3% de la variabilidad en la demanda
- En promedio, las predicciones tienen un error de 70.5%
- Error típico: ± 3 unidades por semana/categoría/región

CASOS DE USO PRINCIPALES:

- 1 ☐ PLANIFICACIÓN DE INVENTARIO (Cada lunes):
 - Input: Ventas de la semana anterior + calendario + stock actual
 - Output: Demanda esperada por categoría-región para la próxima semana
 - Acción: Ajustar niveles de stock, transferencias entre regiones
- 2 ☐ COMPRAS Y REPOSICIÓN (Semanal):
 - Input: Predicciones + stock actual + lead times de proveedores
 - Output: Cantidad a ordenar por categoría
 - Acción: Generar órdenes de compra automáticas
- 3 ☐ ESTRATEGIA COMERCIAL (Mensual):
 - Input: Tendencias de demanda + estacionalidad
 - Output: Identificar oportunidades de crecimiento
 - Acción: Planificar promociones, descuentos, nuevos productos
- 4 ☐ GESTIÓN DE RIESGO (Continuo):
 - Input: Predicciones vs reales + alertas
 - Output: Detección de anomalías en demanda
 - Acción: Respuesta rápida a cambios inesperados

IMPACTO ECONÓMICO ESTIMADO:

SITUACIÓN ACTUAL:

- Demanda semanal promedio: 56 unidades
- Ventas semanales estimadas: \$835
- Error de predicción actual: 70.5%

BENEFICIOS ESTIMADOS:

- Reducción de error: -45.5%
- Ahorro semanal estimado: \$-38
- AHORRO ANUAL ESTIMADO: \$-1976

FUENTES DE VALOR:

- Reducción de stock-outs (-30% ventas perdidas)
- Optimización de inventario (-15% costos de almacenamiento)
- Mejor planificación de compras (-10% costos de urgencia)
- Reducción de obsoletos (-20% productos vencidos)